«Разработка системы анализа производственных заявок и прогнозирования трудоёмкости их выполнения с использованием NLP»

Работу выполнил: студент группы ИС-О-22/1 Демин А. А.

Цель и задачи работы

Цель:
Разработка и внедрение информационной системы на основе NLP и машинного обучения для автоматической оценки трудоёмкости производственных заявок.

Объект исследования:
Производственные IT-заявки.

Предмет исследования:
Методы и алгоритмы для анализа производственных заявок и прогнозирования трудоёмкости их выполнения.

Задачи:
1. Подготовка обучающей выборки.
2. Предварительная обработка обучающей выборки и заявок.
3. Извлечение именованных сущностей (NER) и частей речи (POS-теггинг).
4. Разработка модели машинного обучения для прогнозирования трудоёмкости выполнения производственных заявок.
5. Разработка графического пользовательского интерфейса для взаимодействия с системой.

Актуальность работы

1. Рост объёмов и сложности производственных IT-заявок делает ручной анализ неэффективным.
2. Оценка трудоёмкости субъективна и зависит от опыта сотрудника. Из-за этого возникают ошибки в планировании.
3. Накопленные архивы заявок не структурированы и не используются для прогнозирования.
4. Необходима автоматическая система на базе NLP и ML для объективной оценки трудозатрат.

BPMN-диаграма процесса обработки производственных IT-заявок

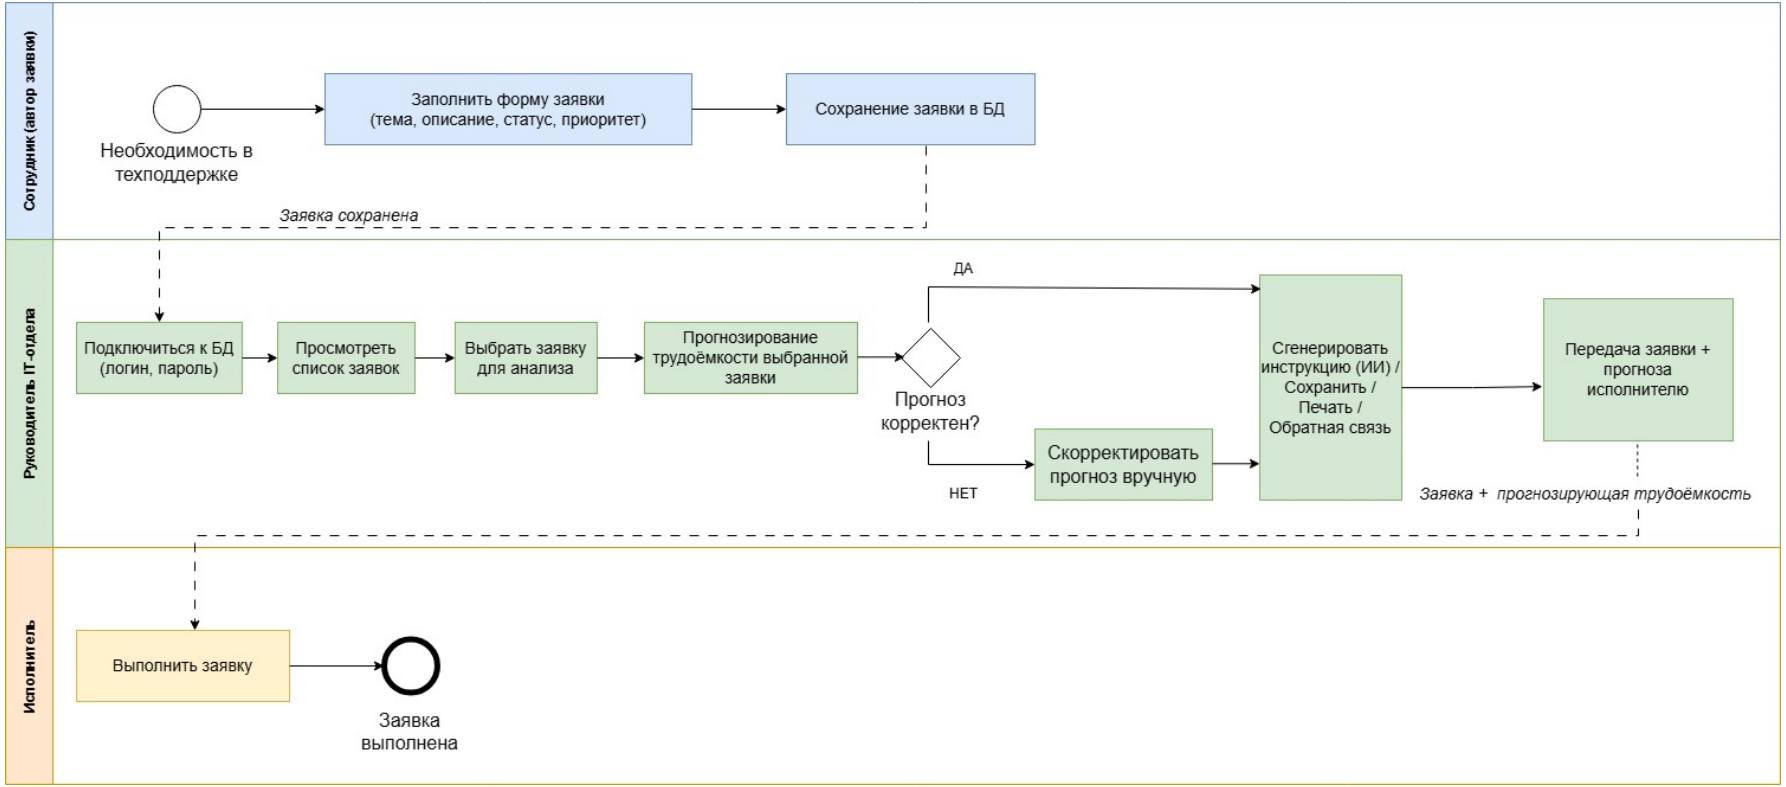

Диаграмма вариантов использования (Use Case) системы

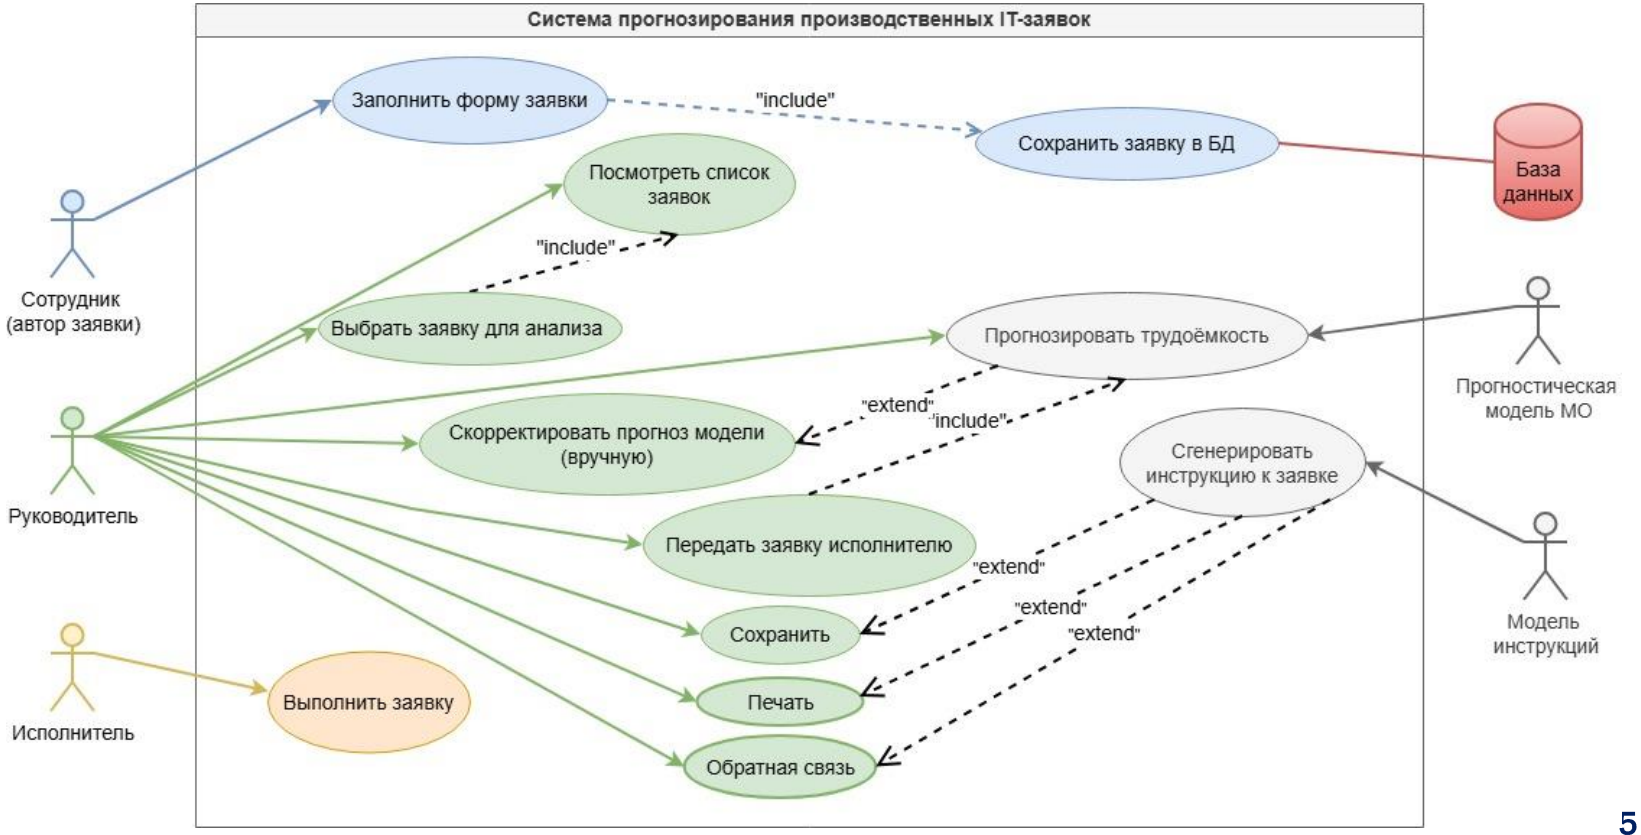

Диаграмма деятельности (Activity diagram) системы

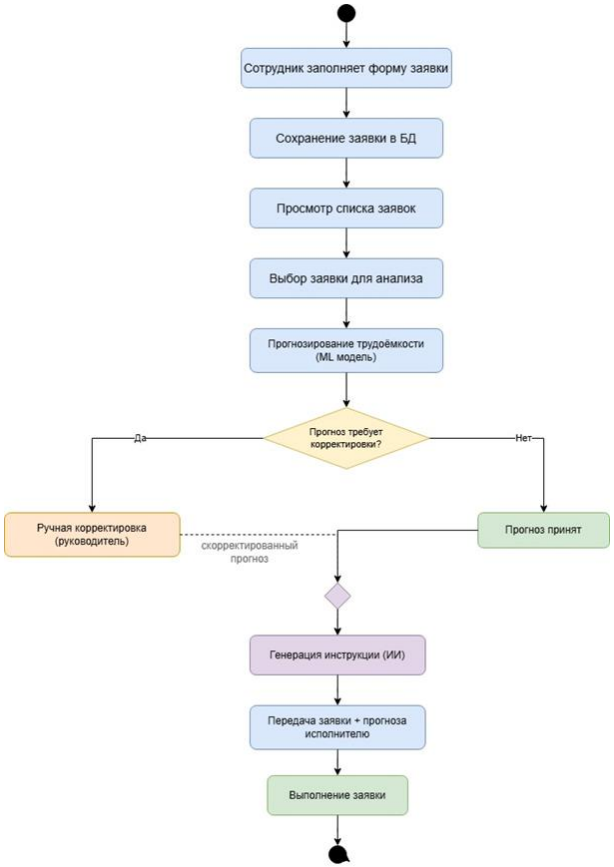

Стек технологий

Язык программирования	Python 3.14.0
Система управления базами данных (СУБД)	PostgreSQL
Среда разработки	Giga IDE
Разработка системы на ОС	Windows 10
Развёртывание системы на ОС	Astra Linux 1.8

Архитектура системы

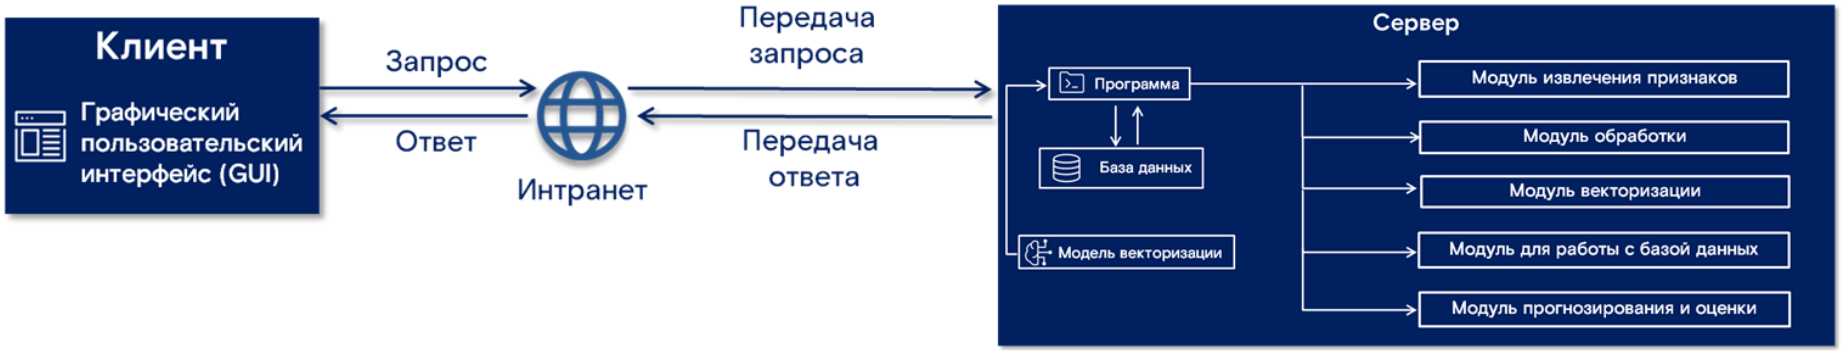

Клиентская часть

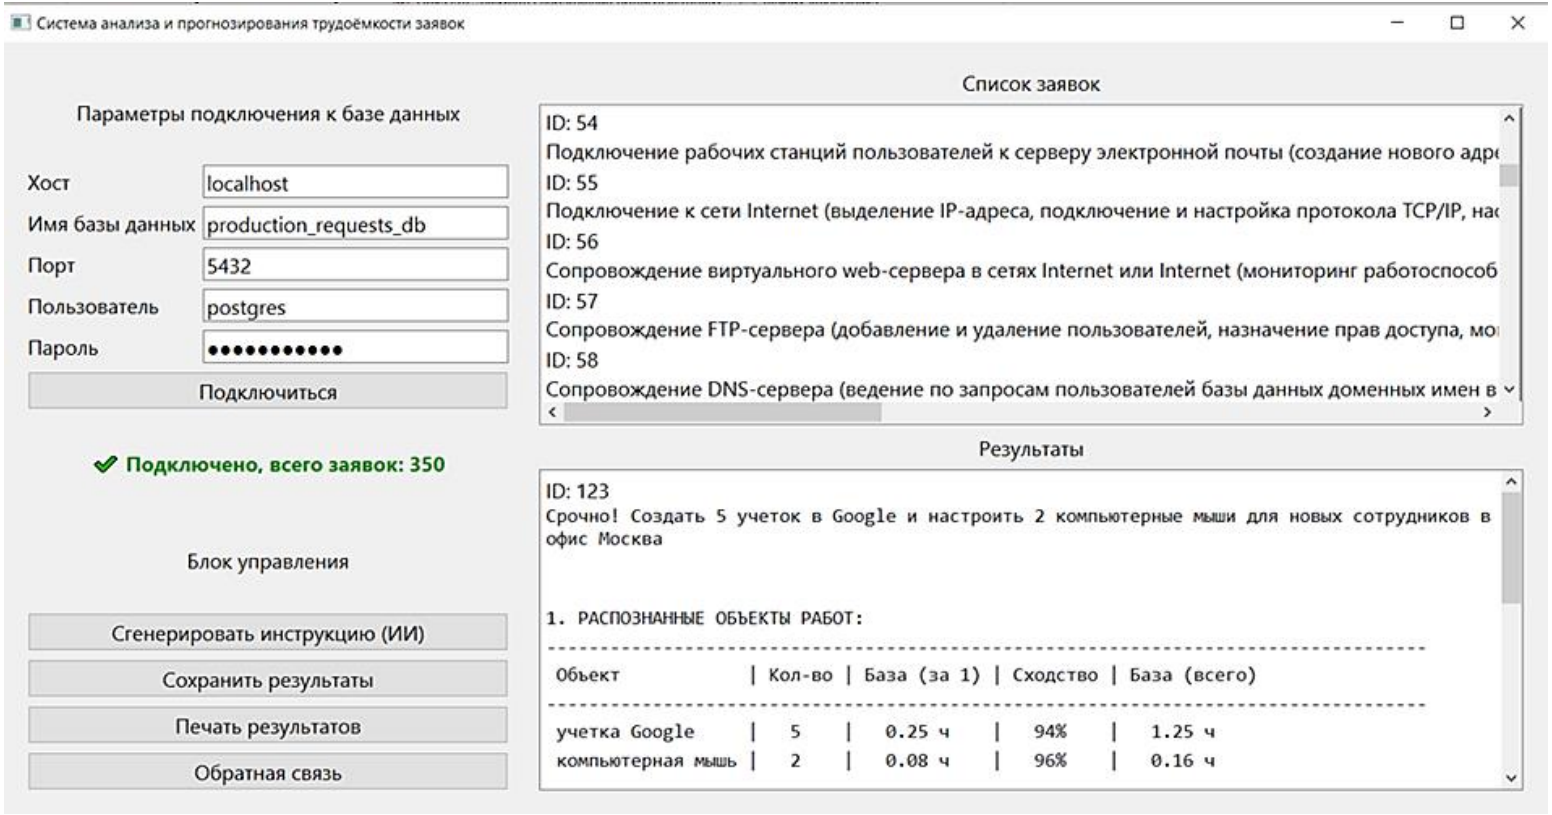

Клиентская часть

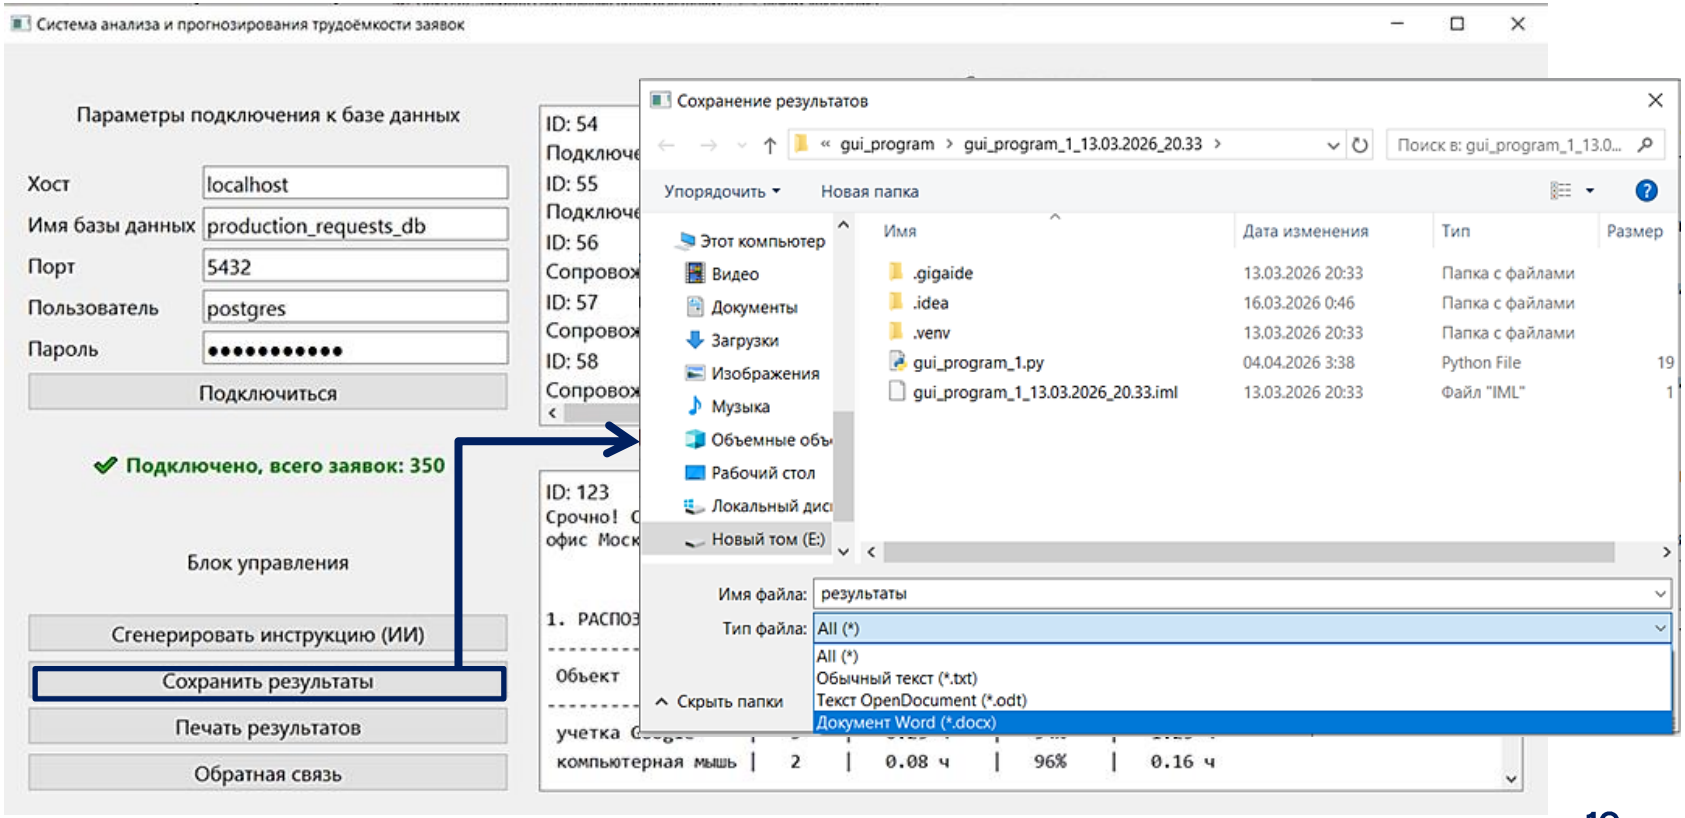

Клиентская часть

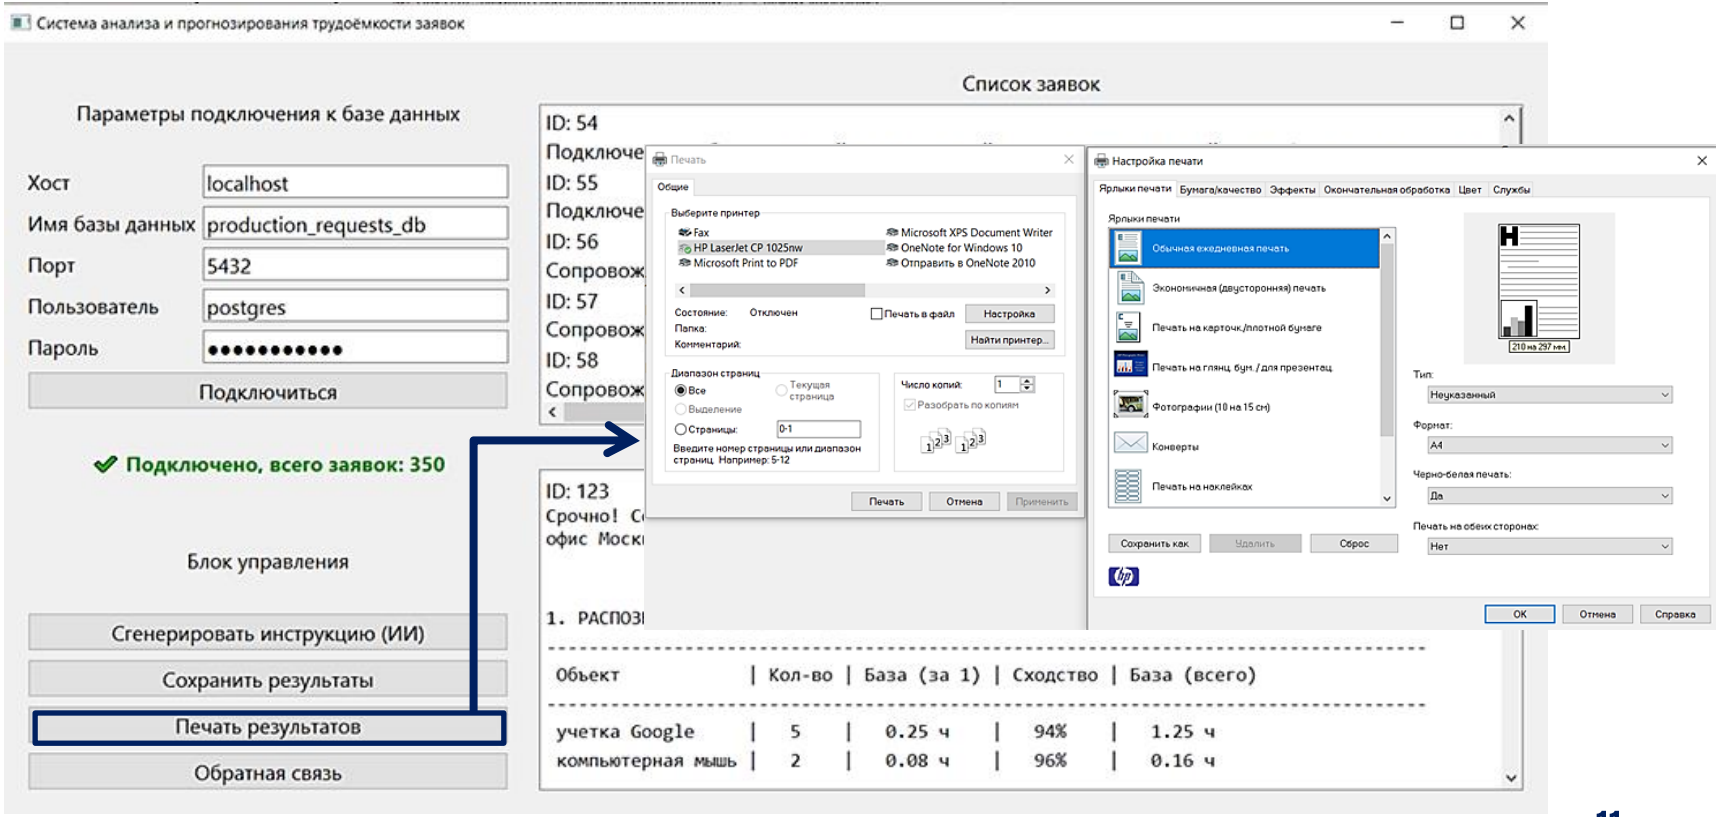

Клиентская часть

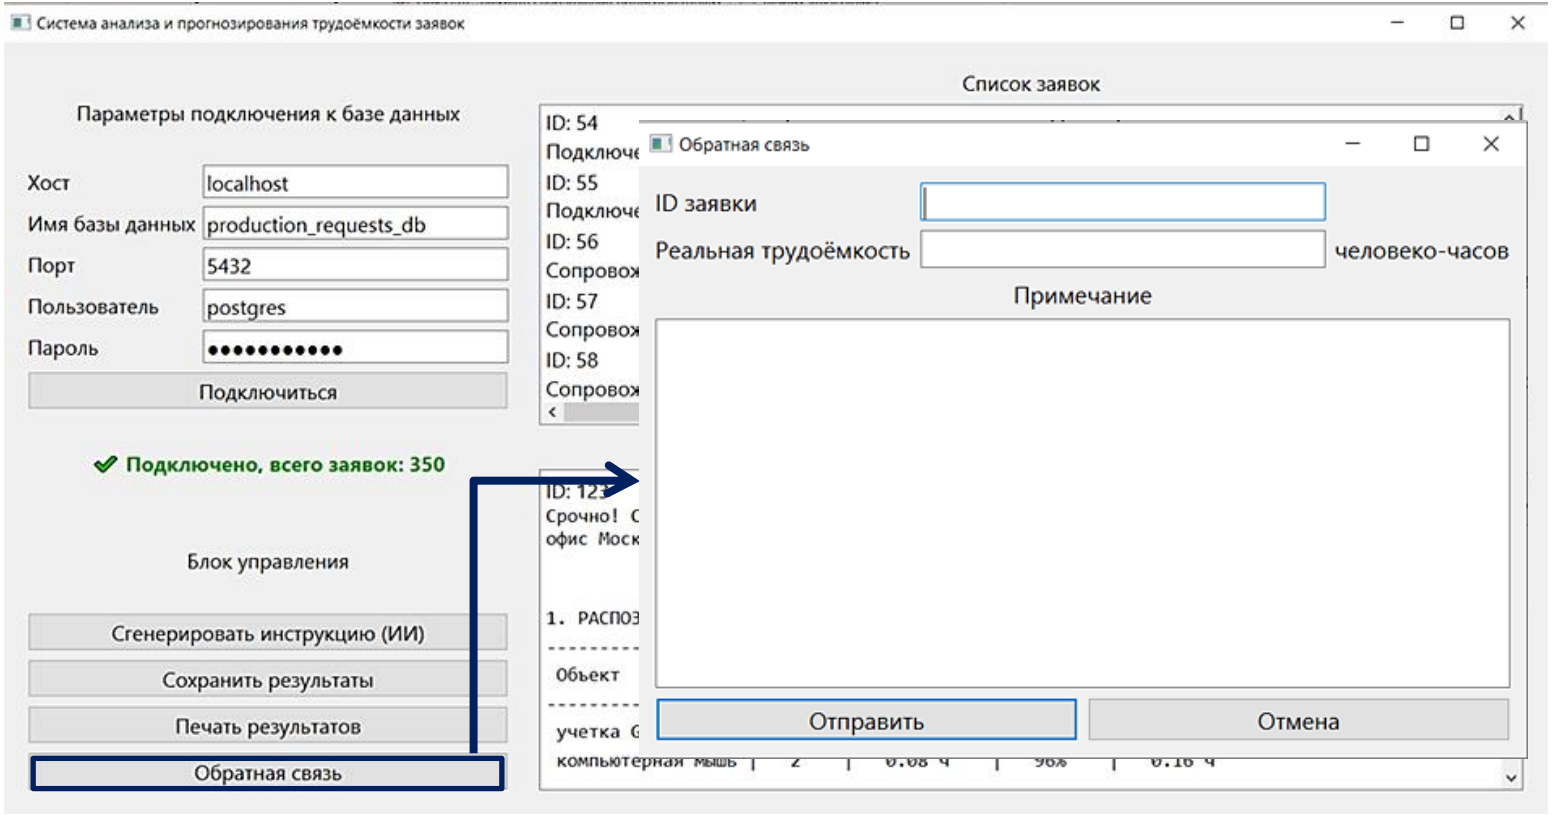

Серверная часть

Модуль извлечения признаков

Извлекаемые сущности (NER):

Тип	Обозначение	Примеры
Персоны	PER	«Иван Петров», «Анна Смирнова»
Локации	LOC	«цех №3», «склад»
Организации	ORG	«Astra Linux», «1С», «Microsoft»

Извлекаемые части речи (POS):

Часть речи	Обозначение	Примеры	Значение для прогноза
Существительные	NOUN	«сервер», «монитор», «кабель»	Объект работы
Глаголы	VERB	«установить», «настроить», «заменить»	Тип операции
Прилагательные	ADJ	«новый», «старый», «серверный»	Характеристика объекта
Числительные	NUM	«5», «2», «100»	Количество

Серверная часть

Модуль извлечения признаков

Извлекаемые сущности (NER):

Тип	Обозначение	Примеры
Персоны	PER	«Иван Петров», «Анна Смирнова»
Локации	LOC	«цех №3», «склад»
Организации	ORG	«Astra Linux», «1С», «Microsoft»

Извлекаемые части речи (POS):

Часть речи	Обозначение	Примеры	Значение для прогноза
Существительные	NOUN	«сервер», «монитор», «кабель»	Объект работы
Глаголы	VERB	«установить», «настроить», «заменить»	Тип операции
Прилагательные	ADJ	«новый», «старый», «серверный»	Характеристика объекта
Числительные	NUM	«5», «2», «100»	Количество

Серверная часть

Модуль извлечения признаков

Инструмент реализации: Natasha + Yargy

Natasha — библиотека для морфологического анализа русского языка.

Yargy — парсер для извлечения структурных блоков.

Модуль обработки

Удаление шума:

Шум — слова, не несущие технической информации и снижающие качество прогноза.

Критерии	Примеры	Способы устранения
Приветствия	«Добрый день!», «Пожалуйста»	Удаление
Предлоги/союзы	«в», «на», «и», «но»	Частотный фильтр НКРЯ* (>500 IPM)
Глаголы-паразиты	«нужно», «требуется», «сделать»	Частотный фильтр НКРЯ* (>300 IPM)
Оценочные прилагательные	«хороший», «быстрый», «качественный»	Частотный фильтр НКРЯ* (>400 IPM)
Слова сложности	«срочно», «высотный», «удаленно»	Извлечение для определения коэффициента

Серверная часть

Модуль обработки

Удаление шума:

Методы фильтрации шума:

Метод фильтрации	Принцип работы	Точность	Скорость	Требует ручного сопровождения	Сложность реализации
POS-фильтрация (Natasha)	Оставление только СУЩ., ГЛ., ПРИЛ., ЧИСЛ.	Средняя	Высокая	Нет	Низкая
Частотный фильтр НКРЯ	Удаление слов с IPM > порога (300–500)	Высокая	Высокая	Нет	Средняя

Модуль векторизации

Методы векторизации текста:

Метод	Тип вектора	Учёт порядка слов	Размерность	Учёт семантики	Скорость обучения	Точность
BERT/Sentence-BERT	Плотный	Есть	Средняя	Есть	Медленная	Очень высокая

Серверная часть

Модуль векторизации

Модель векторизации:

Параметр	USER2-small
Архитектура	RuModernBERT
Размер модели	34M*
Длина контекста	8192
Точность на русском	Высокая
Обработка сложных заявок (>128 токенов)	Да

```python
from sentence_transformers import SentenceTransformer
import numpy as np
model = SentenceTransformer("deepvk/USER2-small", truncate_dim=128)
requests = [
    "Не открывается 1С после обновления",
    "Выдать доступ к сетевой папке",
    "Срочно! Не включается компьютер",
    "Настроить удалённый доступ к почте",
    "Проблема с печатью на принтере"
]
embeddings = model.encode(requests)
print(f"Размерность: {embeddings.shape[1]}\n")
for i, (req, vec) in enumerate(zip(requests, embeddings), 1):
    print(f"{i}. {req}")
    print(f"   Вектор (128): [{', '.join([f'{x:.3f}' for x in vec])}]")
    print()
```

```
Loading weights: 100%|▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰▰| 74/74 [00:00<00:00, 396.03it/s, Materializing param=layers.11.mlp_norm.weight]
Размерность: 128

1. Не открывается 1С после обновления
   Вектор (128): [-0.358, -0.194, 0.050, 0.107, 0.239, 0.367, 0.220, -0.099, 0.483, -0.131, -0.134, -0.163, 0.098, -0.358, -0.298, -0.226, 0.232,

2. Выдать доступ к сетевой папке
   Вектор (128): [-0.434, -0.194, 0.191, 0.352, -0.463, 0.935, 0.498, -0.431, -0.117, -0.092, 0.293, 0.200, 0.383, -0.133, 0.009, -0.145, 0.425, 0.

3. Срочно! Не включается компьютер
   Вектор (128): [-0.753, -0.337, -0.299, 0.014, -0.263, 0.695, 0.154, -0.457, 0.048, -0.205, 0.268, -0.288, 0.463, -0.589, -0.043, 0.329, 0.501,

4. Настроить удалённый доступ к почте
   Вектор (128): [-0.154, -0.001, 0.343, 0.233, -0.210, 0.297, 0.465, 0.011, -0.008, -0.174, 0.131, 0.192, 0.300, -0.451, 0.087, -0.311, 0.400, 0.

5. Проблема с печатью на принтере
   Вектор (128): [-0.232, -0.201, 0.085, -0.161, -0.167, 0.163, 0.307, -0.249, 0.123, -0.126, 0.214, -0.498, 0.116, -0.233, -0.019, -0.310, 0.448,
```

Серверная часть

Модуль прогнозирования и оценки

Модель прогнозирования трудоёмкости: CatBoost.

Модель / Метод	Принцип работы	Преимущества	Недостатки / Ограничения
CatBoost (Градиентный бустинг на деревьях)	Гибридный подход: объединяет эмбеддинги, количественные параметры (количество, вес) и статистику из Natasha.	Автоматически обрабатывает текстовые и категориальные признаки (ORG, LOC) Выявляет сложные зависимости Менее чувствителен к выбросам и шуму в данных	Требует больше вычислительных ресурсов для обучения

Серверная часть

Модуль для работы с базой данных

ERD-диаграмма базы данных:

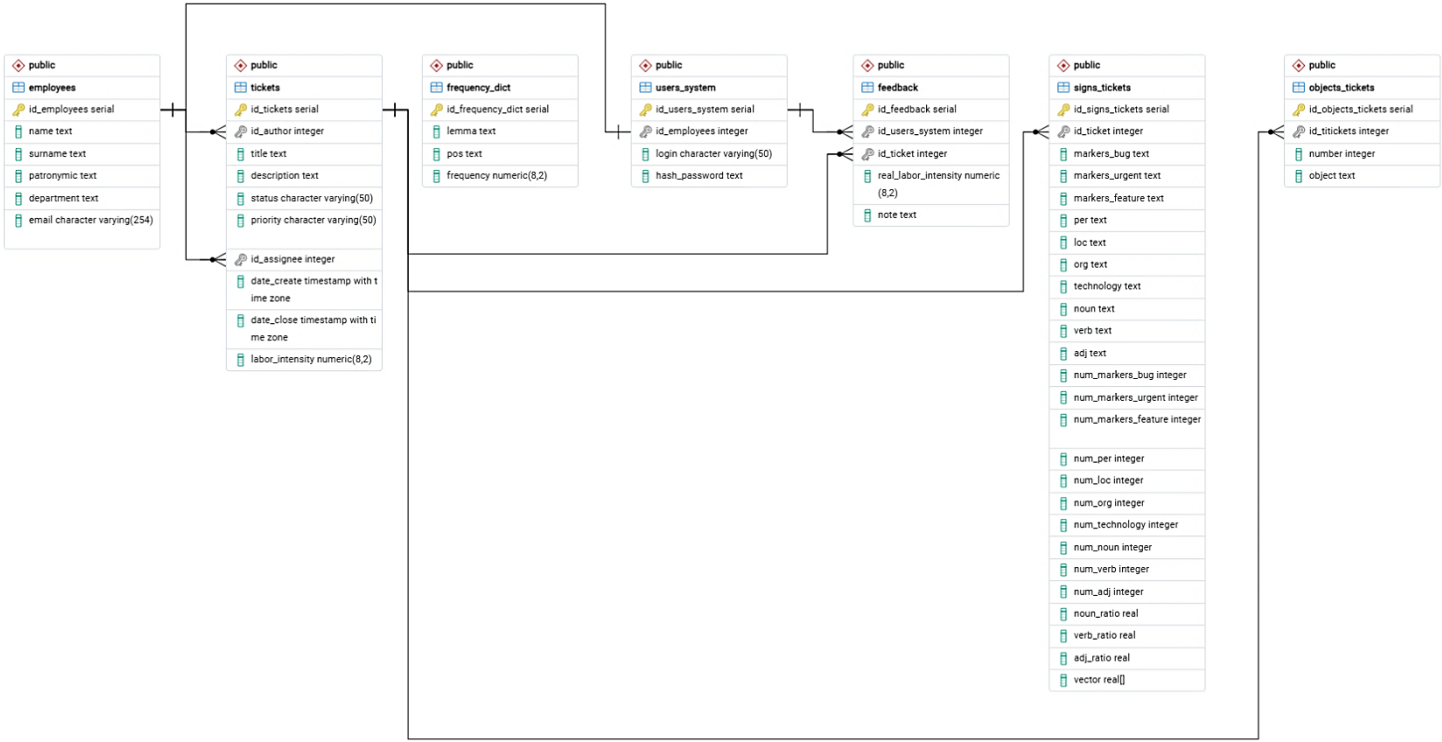

Перспективы

1. Извлечение из IT-заявок технологии с помощью модели **xlm-roberta-large-finetuned-conll03-english.**
   Например, из IT-заявок извлекать такие технологии:
   REST, Python, PostgreSQL React.js Docker GitLab

2. Добавление в систему подбор исполнителей к IT-заявкам.

3. Доработка функции «Сгенерировать инструкцию».